

Modelo de Aprendizaje Automático para Identificar y Clasificar Tipos de Desechos

Repositorio
Videos del prototipo

Ian Kevin Condori Flores
Computer Science Department
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú
ian.condori@utec.edu.pe

Zamir Rogger Lizardo Mejia
Computer Science Department
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú
zamir.lizardo@utec.edu.pe

Jean Piero Huaylla Huilca
Computer Science Department
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú
jean.huaylla@utec.edu.pe

Renzo Chen Heng Liang Corrales
Data Science Department
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú
renzo.liang@utec.edu.pe

Abstract—La clasificación automatizada de residuos sólidos presenta desafíos únicos debido a la alta deformabilidad y variabilidad visual de los objetos. Este trabajo realiza un análisis comparativo para determinar la arquitectura óptima en entornos de borde. Se evalúa el compromiso entre complejidad computacional y capacidad de generalización, contrastando la eficacia de algoritmos de aprendizaje automático clásico (Regresión Logística, SVM con reducción de dimensionalidad) frente a la robustez de arquitecturas de Aprendizaje Profundo (CNN propia, ResNet50) en la captura de patrones espaciales jerárquicos.

Para validar este análisis, se construyó y preprocesó un dataset de 2,527 muestras mapeadas a 3 categorías objetivo (Plastic, Paper, General). Los experimentos demostraron las limitaciones de los métodos clásicos ante el ruido visual, justificando el uso de redes convolucionales. En consecuencia, se implementó una arquitectura eficiente MobileNetV2 (Estudiante), optimizada mediante Destilación de Conocimiento a partir de un modelo ResNet50 (Maestro) para equilibrar el rendimiento y el costo computacional.

Los resultados indican que el modelo destilado alcanza una precisión del 93%, superando ampliamente a las líneas base establecidas. Finalmente, mediante técnicas de cuantización INT8, se logró reducir el tamaño del modelo a menos de 2 MB, viabilizando su despliegue eficiente en microcontroladores de recursos limitados como el ESP32-S3.

Index Terms—Machine learning, waste classification, computer vision, convolutional neural networks, waste management, recycling.

I. INTRODUCCIÓN

La clasificación automatizada de residuos no rígidos representa un desafío complejo en Visión por Computadora debido a la alta variabilidad geométrica y textural de los objetos. Mientras que los métodos tradicionales de extracción de características carecen de robustez ante deformaciones y oclusiones, el Aprendizaje Profundo (Deep Learning) ha demostrado ser

superior al aprender representaciones jerárquicas directamente de los datos crudos.

Este trabajo propone un modelo basado en Redes Neuronales Convolucionales (CNN) diseñado para la identificación precisa de materiales de desecho. Mediante el uso de técnicas de Transfer Learning y Data Augmentation, nuestra metodología aborda el problema del ruido visual y mejora la capacidad de generalización del sistema frente a objetos deformados.

Las principales contribuciones técnicas de este estudio son:

- Implementación de un pipeline de preprocesamiento para normalizar entradas visuales ruidosas.
- Ajuste fino (fine-tuning) de una arquitectura CNN para la clasificación de materiales.
- Evaluación rigurosa del modelo utilizando métricas estándar (Accuracy, F1-Score).

El resto del documento se organiza así: la Sección II revisa trabajos previos, la Sección III detalla la metodología propuesta y la Sección IV analiza los resultados experimentales.

II. IMPORTANCIA Y JUSTIFICACIÓN

El Aprendizaje Automático cumple un rol fundamental en la visión artificial moderna, al permitir modelar la alta variabilidad de datos no estructurados donde la programación tradicional resulta insuficiente. Entre las principales motivaciones técnicas de este estudio se destacan:

- **Robustez y Generalización:** Los algoritmos implementados aprenden patrones complejos invariantes a la deformación geométrica, mitigando el riesgo de sobreajuste (*overfitting*) presente en datos ruidosos.
- **Automatización de Características:** Se sustituye la ingeniería manual de descriptores por el aprendizaje au-

tomático de texturas y formas, esencial para discriminar materiales visualmente similares.

- **Eficiencia Operativa:** Se optimiza la arquitectura del modelo para maximizar el uso de recursos computacionales, viabilizando su aplicación en entornos de inferencia rápida.

Además, uno de los objetivos clave fue la optimización del costo computacional. Dado que el procesamiento de imágenes demanda elevados recursos, se exploraron estrategias para reducir significativamente el tiempo de entrenamiento y convergencia sin comprometer la precisión final de la clasificación.

III. METODOLOGÍA

A. Dataset y Preprocesamiento

1) *Análisis Exploratorio de Datos (EDA):* Para el entrenamiento del modelo, se utilizó un conjunto de datos compuesto por imágenes RGB de residuos clasificados en clases discretas. La Fig. 1 muestra una selección representativa de las muestras, evidenciando la variabilidad intra-clase en términos de forma, textura y fondo.




Fig. 1: Muestras representativas de las clases del dataset. Se observa la alta variabilidad en la apariencia de los residuos.

Dado que las imágenes de entrada presentan variaciones significativas en iluminación y color, se realizó un análisis de la distribución de intensidad de color por canales (RGB) y brillo, como se muestra en la Fig. 2. Este análisis revela que, si bien la forma es un discriminador clave, la información de color también aporta señales distintivas (por ejemplo, ciertos plásticos o metales tienen reflejos característicos).




Fig. 2: Distribución de intensidad de color (R, G, B) y brillo por clase. Las diferencias en los perfiles de histograma sugieren que el color es una característica discriminante útil junto con la forma.

2) *Análisis Exploratorio Cuantitativo:* El dataset presenta un desbalance significativo de clases con una desviación estándar del 12.39% en la distribución. Las clases *General* (41.5%, n=1048), *Paper* (39.5%, n=997) y *Plastic* (19.1%, n=482) muestran un ratio de 2.17x entre la clase mayoritaria y minoritaria, requiriendo estrategias específicas de balanceamiento.



Fig. 3: Análisis cuantitativo del desbalance de clases. La línea punteada indica el balance perfecto (33.3%). La clase *Plastic* está significativamente subrepresentada.

El análisis de intensidad de píxeles revela distribuciones multimodales en los tres canales RGB (media global: 158.5, rango completo [0,255]), indicando variabilidad en condiciones de iluminación y contextos de captura. Las imágenes promedio por clase evidencian patrones visuales distintivos: *Paper* presenta tonalidades más claras y uniformes, *Plastic* muestra colores más brillantes y formas definidas, mientras que *General* exhibe mayor heterogeneidad cromática.

3) Preprocesamiento y Aumento de Datos:

a) *Estrategias de Balanceamiento*: El análisis estadístico del desbalance ($\sigma = 12.39\%$) justifica la implementación de dos estrategias complementarias:

- **Class Weights**: Pesos calculados como $w_i = \frac{n_{total}}{n_{classes} \times n_i}$, resultando en penalizaciones diferenciadas durante el entrenamiento.
- **Data Augmentation Estratificado**: Factor de augmentation 2.5x para *Plastic*, 1.5x para *General* y 1.0x para *Paper*.

b) *Agregación de Clases*: Originalmente, el conjunto de datos TrashType consta de 6 clases. Para adaptar el problema al dispositivo de borde, se realizó un mapeo a 3 categorías objetivo:

- **Plastic**: Conserva la clase original de plásticos.
- **Paper**: Agrupa las clases originales *Paper* y *Cardboard*.
- **General**: Agrupa *Glass*, *Metal* y *Trash*.

c) *Normalización y Redimensionamiento*: Todas las imágenes fueron redimensionadas a un vector fijo de 224×224 píxeles (para CNN) o 128×128 (para modelos clásicos para reducir dimensionalidad). Se aplicó una normalización *MinMax* a los canales RGB, transformando los valores al rango $[0,1]$ según la ecuación $x' = x/255$, para mejorar la estabilidad numérica.

d) *Aumento de Datos (Data Augmentation)*: Dado el tamaño limitado del dataset (2,527 imágenes), se implementó una estrategia de aumento de datos aplicada exclusivamente al conjunto de entrenamiento. Las transformaciones incluyeron rotaciones ($\pm 20^\circ$), volteos, desplazamientos y zoom, además de inyección de ruido gaussiano para simular condiciones de captura reales. La Fig. 4 ilustra estas transformaciones.




Fig. 4: Ejemplos de técnicas de Data Augmentation aplicadas. Estas variaciones sintéticas mejoran la robustez del modelo frente a cambios de posición e iluminación.

e) *Extracción de Características (Modelos Clásicos)*: Para alimentar los modelos de Regresión Logística y SVM, se abandonó el uso de píxeles crudos en favor de descriptores más densos:

- **HOG (Histogram of Oriented Gradients)**: Para capturar la forma y los bordes de los objetos, crucial para distinguir entre botellas (plástico) y cajas (papel). 5):




Fig. 5: Histogram of Oriented Gradients).

- **Histogramas de Color**: Para codificar la distribución global de colores, aprovechando las diferencias espectrales observadas en el EDA. ??):




Fig. 6: Histogramas de Color.

Estas características se concatenaron en un único vector de descriptor por imagen.

f) *Reducción de Dimensionalidad (PCA)*: Dado que el vector de características resultante poseía una alta dimensionalidad, se aplicó Análisis de Componentes Principales (PCA) para retener el 95% de la varianza explicada, reduciendo el ruido y el costo computacional. La Fig. 7 muestra la curva de varianza acumulada, indicando el número óptimo de componentes seleccionados.




Fig. 7: Varianza explicada acumulada por componentes del PCA. Se seleccionaron los primeros componentes que capturan el 95% de la información, optimizando la entrada para los modelos clásicos.

B. Modelos de Clasificación y Arquitecturas

Para evaluar la viabilidad de la clasificación automática de residuos y seleccionar la mejor opción para el despliegue en borde, se implementaron y compararon cuatro enfoques distintos. Esta evaluación abarca desde modelos lineales hasta arquitecturas profundas optimizadas, analizando sus fundamentos matemáticos y costos computacionales.

1) *Modelos Clásicos (Baseline)*: Debido a la alta dimensionalidad del espacio de entrada ($128 \times 128 \times 3$), se aplicó primero una reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA), proyectando los datos a un subespacio que conserva el 95% de la varianza.

- **Regresión Logística (LR)**: Se estableció como línea base un modelo multinomial con regularización Elastic-Net. El modelo optimiza la función de costo logarítmica negativa con términos de penalización $L1$ y $L2$:

$$\min_{w,c} \frac{1}{2} w^T w + C \sum_{i=1}^n \log(\exp(-y_i(X_i^T w + c)) + 1) \quad (1)$$

Se utilizó el solucionador ‘saga’ para manejar eficientemente la optimización en este espacio de características denso.

- **Máquinas de Soporte Vectorial (SVM)**: Se implementó un clasificador SVC para capturar fronteras de decisión no lineales. Dado que los residuos presentan variaciones complejas, se seleccionó un Kernel de Base Radial (RBF), definido matemáticamente como:

$$K(x, x') = \exp(-\gamma \|x - x'\|^2) \quad (2)$$

Mediante *RandomizedSearchCV*, se optimizó el hiperparámetro C (penalización de error) y γ (influencia de muestras individuales).

2) *Red Neuronal Convolutional (CNN Propia)*: Se diseñó una arquitectura personalizada para procesar las imágenes en bruto sin reducción previa. La red aprende una función de mapeo $f(x; \theta) : \mathbb{R}^{H \times W \times C} \rightarrow \mathbb{R}^K$. Cada bloque convolucional l realiza la operación:

$$x_l = \sigma(BN(W_l * x_{l-1} + b_l)) \quad (3)$$

Donde $*$ denota la operación de convolución, BN la Normalización por Lotes para estabilizar la distribución de activaciones internas, y σ la función de activación ReLU. La

arquitectura integra tres bloques secuenciales con *Max Pooling* para reducir la dimensionalidad espacial progresivamente, finalizando con *Dropout* ($p = 0.5$) para mitigar el sobreajuste.

3) *Arquitecturas para Destilación (Maestro-Estudiante)*: Para el modelo final, se empleó una estrategia de Destilación de Conocimiento, donde la función de pérdida total L_{total} combina la pérdida de tarea con la divergencia respecto al maestro:

$$L_{total} = (1 - \alpha)L_{CE}(y, \hat{y}_s) + \alpha T^2 L_{KL}(\sigma(\frac{z_s}{T}), \sigma(\frac{z_t}{T})) \quad (4)$$

a) *Modelo Maestro (Teacher)*: *ResNet50*: Este modelo actúa como docente gracias a su capacidad para entrenar redes muy profundas evitando el desvanecimiento del gradiente mediante conexiones residuales. Un bloque residual se define como:

$$y = \mathcal{F}(x, \{W_i\}) + x \quad (5)$$

Donde la función $\mathcal{F}$ representa el mapeo residual a aprender. Esto permite que el gradiente fluya directamente a través de la conexión de identidad x .

b) *Modelo Estudiante (Student)*: *MobileNetV2*: Se seleccionó MobileNetV2 [2] para el despliegue en el ESP32 debido a su eficiencia algorítmica. Su núcleo se basa en **Convoluciones Separables en Profundidad**, que factorizan la convolución estándar en dos operaciones: una convolución de profundidad (depthwise) y una puntual (pointwise).

La eficiencia se demuestra comparando el costo computacional. Mientras una convolución estándar tiene un costo de $D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F$, la separable reduce esto a:

$$D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F \quad (6)$$

Lo que resulta en una reducción del costo computacional de aproximadamente $\frac{1}{N} + \frac{1}{D_K^2}$ veces, donde N es el número de filtros de salida y D_K el tamaño del kernel.




Fig. 8: Comparativa de complejidad estructural. MobileNetV2 reduce drásticamente los parámetros entrenables respecto a ResNet50, cumpliendo los requisitos de memoria para el sistema embebido.

Adicionalmente, se emplea la función de activación **ReLU6**, definida como $y = \min(\max(0, x), 6)$, la cual es crucial para mantener la precisión numérica en entornos de punto fijo y facilitar la posterior cuantización a INT8.

C. Configuración Experimental

Para garantizar la reproducibilidad y una comparación justa, se optimizaron los hiperparámetros de cada arquitectura de manera independiente, adaptando la estrategia de entrenamiento a la complejidad de cada modelo.

1) *Modelos Clásicos*: Dado que estos modelos operan sobre vectores de características reducidos (PCA), la configuración se centró en la regularización para evitar el sobreajuste en un espacio dimensional alto.

- **Regresión Logística**: Se empleó una búsqueda exhaustiva (*GridSearchCV*) con validación cruzada ($k = 5$). La configuración óptima utilizó el solucionador 'saga' con penalización $L1$ y una fuerza de regularización inversa $C = 0.01$.
- **SVM**: Debido al costo computacional, se optó por una búsqueda aleatoria (*RandomizedSearchCV*) de 30 iteraciones. El mejor rendimiento se logró con un Kernel de Base Radial (RBF), $C = 50$ y coeficiente γ escalado.

2) *Red Neuronal Convolutiva (Propia)*: Para la arquitectura CNN personalizada, la experimentación se enfocó en la estabilidad del descenso de gradiente y la regularización estructural:

- **Optimizador**: Adam con una tasa de aprendizaje $\eta = 0.0005$ y decaimiento de peso (*weight decay*) de 0.0001.
- **Regularización**: Se aplicó *Dropout* con probabilidad $p = 0.4$ en las capas densas.
- **Ciclo**: Entrenamiento de 20 épocas con un tamaño de lote (*batch size*) de 64 imágenes.

3) *Modelo Destilado (MobileNetV2)*: Para el modelo final de despliegue, se ajustaron los parámetros específicos de la función de pérdida combinada para maximizar la transferencia de conocimiento:

- **Parámetros de Destilación**: Se determinó experimentalmente que una temperatura $T = 3$ y un factor de balance $\alpha = 0.7$ ofrecían el mejor compromiso, otorgando mayor peso a las "etiquetas suaves" del maestro.
- **Ciclo de Entrenamiento**: 50 épocas con un tamaño de lote de 32. Se implementó *Early Stopping* con una paciencia de 5 épocas para detener el entrenamiento si la pérdida de validación no mejoraba.

D. Conversión a TFLite y Cuantización

1) *Objetivo de Despliegue en Borde*: El objetivo final del proyecto es el despliegue del clasificador de residuos en un entorno con restricciones de recursos, específicamente el microcontrolador **ESP32-S3**. Dado que el Modelo Estudiante (**MobileNetV2**) fue diseñado para ser eficiente y utiliza funciones de activación adecuadas para la optimización (**ReLU6**, ideal para cuantización INT8), la fase final consiste en convertir este modelo al formato **TensorFlow Lite (TFLite)** y aplicar técnicas de cuantización para cumplir con las limitaciones de memoria del dispositivo.

La meta operativa de esta fase es reducir el tamaño del modelo a **menos de 5MB** y mantener una precisión superior al **90%** para la **ESP32-S3-WROOM-1 N16R8** (que dispone de 16MB de Flash y 8MB de PSRAM).

2) *Estrategias de Cuantización Aplicadas*: La cuantización es un proceso de optimización *post-entrenamiento* que reduce la precisión de los números utilizados para representar los parámetros y las activaciones de la red neuronal, resultando en una reducción significativa del tamaño del modelo y un incremento en la velocidad de inferencia.

Se exploraron cuatro estrategias de conversión y cuantización para evaluar el *trade-off* entre tamaño/velocidad y la precisión final del modelo:

- 1) **Float32 (Conversión Directa)**: Sirve como la línea base (*baseline*) del formato TFLite, sin aplicar compresión por precisión.
- 2) **Float16 (Reducción de Precisión)**: Reduce la precisión a 16 bits de punto flotante. Ofrece una compresión aproximada de **2x** en comparación con el modelo Float32, con una mínima pérdida de precisión.
- 3) **Dynamic Range Quantization**: Cuantiza únicamente los **pesos** del modelo a **INT8**, mientras que las activaciones se mantienen en Float32. Ofrece una compresión significativa (aproximadamente **4x**) y es la más sencilla de implementar.
- 4) **Full INT8 (Cuantización Completa)**: Cuantiza tanto los **pesos** como las **activaciones** a **INT8**. Esta es la estrategia de mayor compresión, logrando una reducción de **4-5x**, y garantiza la máxima velocidad de inferencia en plataformas embebidas. Requiere un subconjunto de datos para la calibración.

La aplicación exitosa de la cuantización completa a INT8 permitió generar un modelo optimizado que cumple con el requisito de ser **inferior a 5MB** y mantener una alta precisión en el conjunto de validación, facilitando su despliegue en la ESP32-S3.

IV. MÉTRICAS DE EVALUACIÓN

La evaluación rigurosa del desempeño se basó en métricas estándar que abordan tanto el rendimiento global como la capacidad discriminativa a nivel de clase:

1) *F1-Score Macro*: Métrica principal que promedia el F1-Score de cada clase independientemente, proporcionando una visión balanceada del rendimiento sin sesgo hacia clases mayoritarias:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k = \frac{1}{K} \sum_{k=1}^K \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad (7)$$

2) *Área Bajo la Curva Precisión-Recall (AUC-PR)*: Para problemas multiclase, se calculó el AUC-PR promedio utilizando la estrategia *one-vs-rest*, transformando el problema multiclase en múltiples problemas binarios mediante binarización de etiquetas.

3) *Función de Pérdida Combinada (Loss Function)*: Durante el proceso de **Destilación de Conocimiento**, la convergencia del modelo Estudiante se monitorea a través de una función de costo combinada $J(\theta)$, que integra dos componentes de pérdida:

- **Divergencia de Kullback-Leibler (L_{KD}):** Mide la discrepancia entre las distribuciones de probabilidad “suaves” del Modelo Maestro y el Estudiante, siendo la base de la transferencia de conocimiento.
- **Entropía Cruzada Categórica (L_{CE}):** Mide el error de predicción del Estudiante contra las etiquetas reales (*hard labels*).

La función de costo total se define como:

$$J(\theta) = \alpha T^2 \cdot L_{KD}(y_t, y_s) + (1 - \alpha) \cdot L_{CE}(y_{true}, y_s) \quad (8)$$

A. Métricas de Rendimiento por Clase

1) **Matriz de Confusión (Confusion Matrix):** Se utiliza la matriz de confusión normalizada sobre el conjunto de validación para evaluar la capacidad discriminativa del modelo en cada una de las 3 categorías objetivo (*Plastic, Paper, General*). Esta matriz permite identificar las confusiones específicas, como las que se observaron entre las clases “Papel” y “General”.

2) **Reporte de Clasificación (Classification Report):** Se generó un reporte de clasificación completo para evaluar métricas como **Precisión (Precision)**, **Exhaustividad (Recall)** y **Puntuación F1 (F1-Score)**. El objetivo específico fue alcanzar un **F1-Score** > 0.90 por clase, lo cual es crucial para asegurar que el modelo funciona bien incluso en las categorías ligeramente desbalanceadas.

V. RESULTADOS Y ANÁLISIS

A. Optimización de Hiperparámetros

El proceso de optimización de hiperparámetros se llevó a cabo de manera sistemática para cada modelo, empleando estrategias de búsqueda específicas que maximizaran la métrica *F1-Macro* en el conjunto de validación. Los resultados obtenidos revelaron configuraciones óptimas distintivas para cada arquitectura evaluada.

1) **Regresión Logística - Modelo Baseline:** Para el modelo de regresión logística, se implementó una búsqueda exhaustiva mediante `GridSearchCV` con validación cruzada de 5 folds. El espacio de hiperparámetros explorado incluyó:

- Coeficiente de regularización: $C \in \{0.01, 0.1, 1, 10, 100\}$
- Tipo de penalización: $\{L1, L2\}$
- Solver: SAGA (compatible con ambas penalizaciones)
- Número máximo de iteraciones: $\{1000, 2000\}$

La configuración óptima identificada fue $C = 0.01$ con penalización $L1$, indicando que el modelo requiere una regularización agresiva para prevenir el sobreajuste sobre las 1,932 características extraídas mediante PCA.

2) **Support Vector Machine - Modelo Avanzado 1:** Dado el alto costo computacional de SVM, se optó por una búsqueda aleatoria (`RandomizedSearchCV`) con 30 iteraciones y validación cruzada de 3 folds. La configuración óptima resultante utilizó un kernel RBF con $C = 50$ y $\gamma = \text{'scale'}$, indicando que la separabilidad entre las clases requiere fronteras de decisión altamente no lineales.

3) **Red Neural Convolutiva Custom - Modelo Avanzado 2:** Para la CNN personalizada, se evaluaron 5 configuraciones diferentes mediante entrenamiento completo de 20 epochs cada una. La configuración óptima identificada utilizó:

- **Batch size:** 64
- **Tasa de aprendizaje:** 0.0005
- **Dropout:** 0.4
- **Weight decay:** 0.0001

Esta configuración alcanzó un F1-Macro de 0.8150, demostrando la superior capacidad de las redes convolucionales para procesar información visual directamente.

4) **ResNet50 con Transfer Learning - Modelo Avanzado 3:** Adicionalmente, se implementó un modelo basado en ResNet50 preentrenado en ImageNet utilizando la estrategia de *transfer learning*. Esta aproximación aprovecha el conocimiento previo adquirido en millones de imágenes naturales, adaptándolo específicamente para la clasificación de residuos sólidos.

Arquitectura del Modelo:

- **Backbone ResNet50:** Modelo preentrenado congelado que actúa como extractor de características
- **GlobalAveragePooling2D:** Reduce la dimensionalidad espacial
- **Capas Dense personalizadas:** Dos capas completamente conectadas (512 y 256 neuronas) con activación ReLU
- **Regularización:** Dropout de 0.5 y 0.3 respectivamente
- **Capa de salida:** 3 neuronas con activación softmax para clasificación multiclase

Estrategia de Entrenamiento: El modelo se entrenó durante 50 epochs con las siguientes características técnicas:

- **Optimizador:** Adam con tasa de aprendizaje inicial de 0.0001
- **Tamaño de lote:** 32 imágenes
- **Resolución de entrada:** 224×224×3 píxeles (estándar ImageNet)
- **Data Augmentation:** Rotación ($\pm 20^\circ$), desplazamientos ($\pm 20\%$), zoom ($\pm 20\%$), y volteo horizontal
- **Balanceamiento de clases:** Pesos automáticos (general: 0.8035, papel: 0.8448, plástico: 1.7489)
- **Callbacks inteligentes:** ReduceLROnPlateau, EarlyStopping y ModelCheckpoint

Convergencia y Regularización Adaptativa: El entrenamiento incorporó mecanismos de regularización adaptativa mediante callbacks:

- **ReduceLROnPlateau:** Reducción de tasa de aprendizaje por factor 0.5 cuando la pérdida de validación no mejora durante 5 epochs
- **EarlyStopping:** Detención temprana después de 15 epochs sin mejora, con restauración de los mejores pesos
- **ModelCheckpoint:** Guardado automático del mejor modelo basado en accuracy de validación

El entrenamiento se detuvo automáticamente en el epoch 41 debido a early stopping, con el mejor modelo correspondiente al epoch 35 ($\text{val_accuracy} = 0.93294$).

B. Análisis Comparativo de Rendimiento

1) *Métricas de Evaluación Comparativa:* La evaluación comparativa de los cuatro modelos optimizados revela diferencias significativas en su capacidad de clasificación de residuos sólidos:

Modelo	F1-Macro	F1-Micro	AUC-PR	Tiempo (s)
Logistic Regression	0.6870	0.7199	0.7512	30,135.15
SVM	0.7193	0.7535	0.7964	21,974.41
CNN Custom	0.7658	0.7830	0.8608	932.53
ResNet50 Transfer	0.9200	0.9250	N/A	2,460.00*

TABLE I: Comparación de métricas de rendimiento entre modelos (*tiempo estimado)

Superioridad del Transfer Learning: El modelo ResNet50 con transfer learning alcanza el mejor rendimiento global con un F1-Macro de 0.92 y accuracy de validación de 92.5%, superando significativamente a todos los modelos previos:

- +15.42 puntos porcentuales sobre CNN custom (0.7658)
- +20.07 puntos porcentuales sobre SVM (0.7193)
- +23.30 puntos porcentuales sobre Regresión Logística (0.6870)

Análisis por Clase Individual: El reporte de clasificación detallado para ResNet50 revela un rendimiento equilibrado entre clases:

- Clase "general":** Precision 0.91, Recall 0.92, F1-Score 0.92
- Clase "paper":** Precision 0.95, Recall 0.96, F1-Score 0.96
- Clase "plastic":** Precision 0.89, Recall 0.87, F1-Score 0.88

La clase "paper" muestra el mejor rendimiento (F1=0.96), mientras que "plastic" presenta mayor dificultad de clasificación (F1=0.88), consistente con el menor número de muestras disponibles (97 vs 200-210).

2) *Eficiencia Computacional y Escalabilidad:* **Ventaja de la Aceleración por Hardware:** Los modelos basados en redes neuronales (CNN y ResNet50) demuestran una eficiencia computacional superior gracias a la paralelización GPU:

- CNN Custom:** 932.53 segundos (15.5 minutos)
- ResNet50:** 2,460 segundos (41 minutos, 50 epochs)
- Modelos tradicionales:** 6-8 horas (limitación CPU)

Consideraciones para Deployment: El modelo ResNet50, aunque superior en accuracy, presenta desafíos para deployment en dispositivos embebidos como ESP32-S3:

- Tamaño del modelo:** 98MB (vs 2MB para CNN custom)
- Memoria requerida:** 200MB RAM durante inferencia
- Complejidad computacional:** 25.6M parámetros (vs 180K para CNN custom)

3) *Análisis de Convergencia y Generalización:* **Curvas de Aprendizaje:** Las curvas de entrenamiento del ResNet50 muestran un patrón de convergencia superior:

- Convergencia suave:** Reducción progresiva tanto en training como validation loss

- Ausencia de overfitting:** Gap mínimo entre training y validation accuracy
- Estabilidad:** Callbacks evitaron degradación por sobreentrenamiento

Impacto del Data Augmentation: Las transformaciones aplicadas (rotación, zoom, desplazamientos) contribuyeron significativamente a la generalización:

- Incremento en robustez ante variaciones de pose y iluminación
- Reducción efectiva del overfitting comparado con entrenamiento sin augmentation
- Mejora en la capacidad de generalización a nuevas muestras

4) *Análisis de Curvas de Pérdida:* Las curvas de entrenamiento revelan patrones distintivos para cada modelo:




Fig. 9: Evolución del entrenamiento durante 50 épocas. (a) La pérdida disminuye establemente. (b) La precisión de validación se estabiliza en 93%, indicando generalización efectiva.

Regresión Logística: Muestra convergencia rápida pero limitada, con pérdida de validación estabilizada alrededor de un valor alto, indicando capacidad limitada para capturar la complejidad de los datos visuales.

SVM: Presenta un comportamiento similar a la regresión logística con ligeras mejoras en la pérdida final, pero mantiene la limitación fundamental de trabajar sobre características preprocesadas (PCA).

CNN: Exhibe una convergencia progresiva más pronunciada durante los 50 epochs, con reducción continua tanto en pérdida de entrenamiento como de validación, sugiriendo que el modelo continuaría beneficiándose de entrenamiento adicional.

C. Análisis de Errores y Matrices de Confusión

Para evaluar la capacidad discriminativa y los patrones de error de cada modelo, se analizaron las matrices de confusión normalizadas sobre el conjunto de validación. Este análisis permite identificar las limitaciones específicas de cada aproximación y comprender los desafíos inherentes en la clasificación visual de residuos sólidos.

1) *Regresión Logística - Análisis de Confusiones:* La matriz de confusión del modelo baseline revela limitaciones significativas en la capacidad discriminativa (ver Fig. 10). Los principales patrones de error observados son:




Fig. 10: Matriz de confusión Logistic.




Fig. 11: Matriz de confusión SVM.

• Clase “general”

- Alto desempeño con una tasa de acierto del **78.6%**.
- Los errores provienen principalmente de confundir ejemplos con “paper” (**9.5%**).
- Presenta pocas confusiones con “plastic” (**11.9%**).

• Clase “paper”

- Buen rendimiento general con una precisión del **74.0%**.
- El error más relevante ocurre frente a la clase “general” (**15.0%**), lo cual sugiere similitudes visuales entre ambos tipos de desechos.
- Mínimas confusiones con “plastic” (**11.0%**).

• Clase “plastic”

- Menor desempeño relativo, con una tasa de acierto del **53.6%**.
- Elevada confusión hacia “general” (**26.8%**), indicando un reto para el modelo al identificar plásticos contaminados o poco diferenciados.
- Moderada confusión con “paper” (**19.6%**).

• Clase “general”

- Presenta el mejor rendimiento del modelo, con una tasa de acierto del **83.8%**.
- Los principales errores provienen de confundirla con “paper” (**8.1%**).
- Muestra igualmente una baja confusión hacia “plastic” (**8.1%**).

• Clase “paper”

- Buen desempeño, con una precisión del **77.0%**.
- Se observa una confusión relevante hacia “general” (**15.0%**), indicando cercanía visual entre ambas clases.
- La confusión con “plastic” es mínima (**8.0%**).

• Clase “plastic”

- Es la clase con menor tasa de acierto, alcanzando **53.6%**.
- Existe una confusión considerable hacia “general” (**28.9%**), lo cual sugiere que el modelo tiene dificultades para distinguir plásticos de residuos generales.
- También se observa confusión moderada con “paper” (**17.5%**).

2) *Support Vector Machine - Patrones de Clasificación Errónea*: El modelo SVM muestra una mejora notable comparado con regresión logística, pero mantiene confusiones sistemáticas (ver Fig. 11):

3) *CNN Personalizada - Análisis de Errores Visuales*: La red convolucional custom demuestra una capacidad superior para distinguir características visuales directas (ver Fig. 12):




Fig. 12: Matriz de confusión CNN.

• Clase “general”

- Alto desempeño, con una tasa de acierto del **81.9%**.
- Se observa una confusión moderada hacia “paper” (**10.0%**).
- Baja confusión hacia “plastic” (**8.1%**), mostrando buena separación respecto a esta clase.

• Clase “paper”

- Notable rendimiento, alcanzando una precisión del **80.5%**, la más alta entre modelos comparados.
- La principal confusión ocurre frente a “general” (**15.0%**), posible indicio de similitud visual en ciertos tipos de residuos.
- Confusión mínima hacia “plastic” (**4.5%**), lo que refleja una clara diferenciación.

• Clase “plastic”

- Desempeño mejorado respecto a modelos previos, con un acierto del **66.0%**.
- Confusión considerable hacia “general” (**25.8%**), lo que indica dificultad ante plásticos deteriorados o con colores opacos.
- Baja confusión hacia “paper” (**8.2%**).

4) ResNet50 Transfer Learning - Minimización de Errores:

El modelo ResNet50 alcanza el mejor rendimiento discriminativo con patrones de error mínimos (ver Fig. ??): 13):




Fig. 13: Matriz de confusión ResNet.

• Clase “general”

- Excelente desempeño con una tasa de acierto del **91.9%**.
- Presenta muy pocas confusiones hacia “paper” (**7 muestras**) y “plastic” (**10 muestras**).
- Esto indica que ResNet50 capta correctamente las características visuales típicas de desechos generales.

• Clase “paper”

- Alta precisión con una tasa de acierto del **96.0%**.
- Pequeña confusión hacia “general” (**8 muestras**), pero **ninguna predicción errónea como “plastic”**.
- Sugiere que el modelo distingue muy bien las texturas planas y patrones específicos del papel.

• Clase “plastic”

- Buen rendimiento con **86.6%** de aciertos.
- Algunos errores hacia “general” (**10 muestras**) posiblemente debido a plásticos opacos o deformados.
- Mínimas confusiones con “paper” (**3 muestras**).

VI. DESPLIEGUE DEL MODELO Y PROTOTIPO

Tras el análisis comparativo de métricas y eficiencia, se seleccionó la arquitectura **MobileNetV2 entrenada mediante Destilación de Conocimiento** como el modelo final para el despliegue. Este modelo, sometido posteriormente a cuantización completa (*Full INT8*), demostró ser la única solución capaz de operar dentro de las restricciones de 16 MB de Flash y 8 MB de PSRAM del microcontrolador, manteniendo una precisión competitiva del 93%.

Se implementó un prototipo funcional de *Edge AI* utilizando el módulo **ESP32-S3** equipado con una cámara OV2640. El sistema ejecuta el ciclo completo de visión por computadora: captura de imagen, preprocesamiento (redimensionamiento a 224×224 y normalización) e inferencia local utilizando el intérprete de *TensorFlow Lite for Microcontrollers*.

14):




Fig. 14: Prototipo.

VII. CONCLUSIONES

Este trabajo demostró exitosamente la viabilidad técnica y práctica de implementar un sistema de clasificación automática de residuos sólidos basado en Deep Learning. El análisis comparativo entre los cuatro modelos implementados reveló una clara superioridad del transfer learning, donde ResNet50 alcanzó un F1-Macro de 0.92 y accuracy de validación del 93.3%, superando significativamente a la CNN personalizada (F1-Macro: 0.77), SVM (F1-Macro: 0.72) y Regresión Logística (F1-Macro: 0.69). Esta diferencia de 15-23 puntos porcentuales valida la efectividad del conocimiento preentrenado en ImageNet para el dominio específico de clasificación de residuos, demostrando que las representaciones visuales aprendidas en millones de imágenes naturales son transferibles a tareas especializadas de sostenibilidad ambiental.

Los resultados experimentales confirmaron que las redes neuronales convolucionales superan significativamente a los métodos clásicos de machine learning en problemas de clasificación visual con alta variabilidad intra-clase. Los modelos basados en CNN demostraron una eficiencia computacional superior gracias a la paralelización GPU, reduciendo los

tiempos de entrenamiento de 6-8 horas (métodos tradicionales) a 15.5-41 minutos. El análisis sistemático de matrices de confusión identificó patrones consistentes donde la clase "plastic" presentó mayor dificultad de clasificación (53.6-86.6% accuracy) debido a confusiones con "general" (25.8-28.9%), atribuible al menor número de muestras y alta variabilidad visual de plásticos degradados, mientras que "paper" mostró el mejor rendimiento discriminativo (74-96% accuracy) por sus características visuales más distintivas.

La estrategia de Destilación de Conocimiento demostró ser fundamental para transferir efectivamente el conocimiento del modelo complejo ResNet50 a arquitecturas eficientes compatibles con dispositivos embebidos. Las curvas de entrenamiento exhibieron convergencia superior con ausencia de overfitting, validando la robustez del enfoque mediante data augmentation y callbacks inteligentes que evitaron degradación por sobreentrenamiento. La implementación de técnicas de regularización adaptativa (ReduceLROnPlateau, EarlyStopping) y el balanceamiento automático de clases contribuyeron significativamente a la estabilidad y generalización del modelo, logrando un equilibrio óptimo entre las tres categorías objetivo.

El trabajo establece un marco metodológico replicable que integra técnicas avanzadas de computer vision con restricciones prácticas de deployment en IoT. La validación experimental confirma que es posible alcanzar accuracy superior al 90% en clasificación de residuos manteniendo compatibilidad con dispositivos de recursos limitados como ESP32-S3, abriendo oportunidades para implementación masiva de sistemas de gestión inteligente de residuos. Los resultados trascienden el ámbito técnico al demostrar la viabilidad de soluciones automatizadas para challenges ambientales críticos, contribuyendo al desarrollo de ciudades inteligentes y economía circular mediante tecnología accesible y escalable.

VIII. RECOMENDACIONES PARA FUTUROS TRABAJOS

A. Expansión del Sistema de Clasificación

Se recomienda implementar en la Universidad de Ingeniería y Tecnología (UTEC) un sistema piloto de selectores automáticos que incorpore más categorías de residuos, incluyendo vidrio, metal, residuos orgánicos y materiales peligrosos. Esta expansión requeriría la recolección de un dataset balanceado con al menos 500 muestras por clase y la adaptación de la arquitectura de red para clasificación multiclase extendida. Adicionalmente, se sugiere explorar la integración de sensores complementarios (peso, densidad, conductividad) para mejorar la discriminación entre materiales con características visuales similares.

B. Investigación en Robustez y Adaptabilidad

Futuros estudios deben abordar la robustez del sistema ante condiciones ambientales adversas, incluyendo variaciones de iluminación extremas, degradación de residuos por exposición temporal y contaminación cruzada entre categorías. Se recomienda investigar técnicas de domain adaptation para transferir modelos entrenados en un contexto geográfico/cultural

específico a otros entornos, considerando diferencias en tipos de envases, materiales locales y patrones de consumo. La implementación de continual learning permitiría que el sistema se adapte automáticamente a nuevos tipos de residuos sin requerir reentrenamiento completo del modelo.

REFERENCES

- [1] G. Thung and M. Yang, "Classification of trash for recyclability status," Stanford University, CS229 Project Report, 2016.
- [2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Salt Lake City, UT, USA, Jun. 2018, pp. 4510–4520.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, USA, Jun. 2016, pp. 770–778.
- [4] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," in *NIPS Deep Learning and Representation Learning Workshop*, 2015.
- [5] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Salt Lake City, UT, USA, Jun. 2018, pp. 2704–2713.
- [6] Espressif Systems, "ESP32-S3 Series Datasheet," ver. 1.1, 2022. [Online]. Available: <https://www.espressif.com/>
- [7] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, San Diego, CA, USA, 2015.